

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

ФГАОУ ВО «НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»

ФПИИ

Образовательная программа: «Языковые модели и ИИ»

Отчёт по дисциплине «Математическая статистика»

Расчётно-графическая работа №1

«Описание выборки. Оценивание параметров. Доверительные интервалы»

Вариант: А-11

Авторы: Лебедев А. Е. (ИСУ 466482),

Попов Г. И. (ИСУ 472374)

Санкт-Петербург, 2026

Содержание

1	Введение: Цели работы и постановка задачи	3
1.1	Цели и задачи исследования	3
1.2	Характеристика исходных данных	4
2	Первичное описание выборки	5
2.1	Вариационный ряд и порядковые статистики	5
2.2	Точечные оценки числовых характеристик (Теоретическая справка) . . .	5
2.3	Построение вариационного ряда	6
2.4	Эмпирические результаты вычислений	6
3	Интервальная группировка и визуализация данных	8
3.1	Теоретическое обоснование методов визуализации	8
3.2	Визуальный анализ переменной X_1	10
3.3	Визуальный анализ переменной X_2	11
3.4	Визуальный анализ переменной X_3	12
4	Идентификация теоретических законов распределения	13
4.1	Теоретические справки по рассматриваемым моделям	13
4.2	Обоснование выбора распределений для X_1, X_2, X_3	13
5	Оценивание параметров теоретических моделей	15
5.1	Теоретико-методологическая база	15
5.2	Оценки для равномерного распределения (Столбец X_1)	16
5.3	Оценки для нормального распределения (Столбец X_2)	17
5.4	Оценки для экспоненциального распределения со сдвигом (Столбец X_3) .	18
6	Оценка параметрической вероятности редких событий	20
6.1	Методология оценивания	20
6.2	Аналитические расчеты для исследуемых величин	21
6.3	Сравнительный анализ вероятностей	21
7	Оценка моментов по сгруппированной выборке	23
7.1	Математическая постановка задачи группировки	23
7.2	Результаты пересчета моментов	23
8	Интервальное оценивание параметров	25
8.1	Асимптотические доверительные интервалы для EX	25
8.2	Точные доверительные интервалы для нормального закона (X_2)	26
8.3	Интерпретация доверительного интервала	26
9	Итоговый вывод по основной части	27

10 Бонус: Анализ бимодальности и кластеризация (X_4)	28
10.1 Визуальный анализ и выявление неоднородности	28
10.2 Обоснование необходимости кластеризации	29
10.3 Результаты разделения смеси (Кластеризация)	29
A Приложение A. Листинг программного обеспечения	30
A Приложение A. Программная реализация	31

1 Введение: Цели работы и постановка задачи

Математическая статистика предоставляет фундаментальный аналитический аппарат для работы с эмпирическими данными. В условиях стохастической природы большинства реальных процессов и ограниченности доступных наблюдений, ключевой задачей исследователя становится не просто фиксация результатов, но и выявление глубинных закономерностей, присущих генеральной совокупности.

1.1 Цели и задачи исследования

Целью данной расчётно-графической работы является проведение полного цикла разведочного (Exploratory Data Analysis) и параметрического статистического анализа для предоставленных наборов многомерных данных.

Для достижения поставленной цели в работе последовательно решаются следующие задачи:

1. **Первичное описание выборки:** вычисление робастных и классических точечных оценок числовых характеристик (математического ожидания, дисперсии, медианы, квартилей).
2. **Визуализация данных:** построение вариационных рядов, эмпирических функций распределения (ЭФР) и гистограмм плотности частот по правилу Стерджеса.
3. **Идентификация вероятностных моделей:** выдвижение статистических гипотез о принадлежности эмпирических распределений к известным теоретическим законам (нормальному $N(a, \sigma^2)$, равномерному $U(a, b)$, экспоненциальному $Exp(\lambda, c)$).
4. **Оценивание параметров:** нахождение неизвестных параметров распределений классическими методами — методом моментов (ММ) и методом максимального правдоподобия (ММП).
5. **Оценка вероятностей редких событий:** анализ попадания случайных величин в «хвосты» распределений (эмпирически и теоретически).
6. **Анализ группированных данных:** оценка потери информации при переходе от исходных наблюдений к интервальным рядам.
7. **Интервальное оценивание:** построение асимптотических и точных доверительных интервалов для оценки точности и надёжности найденных параметров.
8. **Кластерный анализ:** выявление признаков неоднородности (бимодальности) в дополнительном наборе данных и разделение смеси распределений.

1.2 Характеристика исходных данных

В качестве исходного материала для проведения исследования выступает набор данных, соответствующий варианту **A-11**. Данные представляют собой выборку из генеральной совокупности и характеризуются следующими параметрами:

- **Объём генеральной выборки (n):** 200 независимых наблюдений (достаточный объём для применения асимптотических свойств Центральной предельной теоремы).
- **Основной аналитический блок:** непрерывные случайные величины X_1, X_2, X_3 . Предполагается, что данные величины генерируются независимыми физическими или информационными процессами и подчиняются базовым законам распределения.
- **Дополнительный аналитический блок:** переменная X_4 , предназначенная для бонусного исследования на предмет выявления скрытых структур и кластеризации.

Вычисления производятся с высокой степенью точности с использованием специализированных программных пакетов для статистической обработки данных на языке Python (библиотеки `numpy`, `pandas`, `scipy.stats`).

2 Первичное описание выборки

Первым этапом любого глубокого статистического анализа является разведочный анализ данных (Exploratory Data Analysis, EDA). На этом этапе сырые данные генеральной совокупности преобразуются в упорядоченные структуры, а также вычисляются базовые точечные оценки, позволяющие сделать первичные выводы о форме и параметрах распределений.

2.1 Вариационный ряд и порядковые статистики

Пусть имеется исходная выборка $X = (x_1, x_2, \dots, x_n)$ объёма $n = 200$, представляющая собой последовательность независимых одинаково распределённых случайных величин.

Вариационным рядом называется та же выборка, элементы которой упорядочены по неубыванию значений. Элементы вариационного ряда называются порядковыми статистиками и обозначаются в круглых скобках:

$$x_{(1)} \leq x_{(2)} \leq x_{(3)} \cdots \leq x_{(n-1)} \leq x_{(n)} \quad (1)$$

где $x_{(1)} = \min(X)$ — первая порядковая статистика (выборочный минимум), а $x_{(n)} = \max(X)$ — n -я порядковая статистика (выборочный максимум). Вариационный размах вычисляется как $R = x_{(n)} - x_{(1)}$.

2.2 Точечные оценки числовых характеристик (Теоретическая справка)

Для перехода от массива сырых данных к компактным информативным показателям вычисляются точечные числовые характеристики. В данной работе применяются следующие оценки.

1. Выборочное среднее ($\bar{x}$). Является несмещённой, состоятельной и эффективной оценкой математического ожидания EX . Вычисляется как среднее арифметическое всех элементов выборки:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2)$$

2. Выборочная (смещённая) дисперсия (S^2). Характеризует меру рассеяния случайной величины относительно её выборочного среднего. Оценка является состоятельной, но смещённой (её математическое ожидание не равно истинной дисперсии генеральной совокупности):

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (3)$$

3. Исправленная (несмещённая) выборочная дисперсия ($\hat{\sigma}^2$). Для устранения смещения выборочной дисперсии вводится поправочный коэффициент Бесселя $\frac{n}{n-1}$.

Данная оценка лишена систематической ошибки:

$$\hat{\sigma}^2 = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (4)$$

4. Выборочное стандартное отклонение (S). Вычисляется как квадратный корень из дисперсии и имеет ту же размерность, что и сама случайная величина, что делает его удобным для интерпретации:

$$S = \sqrt{S^2} \quad (5)$$

5. Выборочная медиана (m_e). Робастная (устойчивая к аномальным выбросам) оценка центра распределения. Медиана делит упорядоченную выборку на две равные по объему части. Для выборки чётного объема ($n = 200$) вычисляется как полусумма двух центральных элементов вариационного ряда:

$$m_e = \frac{x_{(100)} + x_{(101)}}{2} \quad (6)$$

6. Квартили (Q_1, Q_3). Значения, делящие выборку на четыре равные части. Первый квартиль Q_1 (25-й перцентиль) отделяет четверть наименьших значений, а третий квартиль Q_3 (75-й перцентиль) — четверть наибольших. Межквартильный размах $IQR = Q_3 - Q_1$ используется для поиска выбросов.

2.3 Построение вариационного ряда

Построение вариационного ряда является первым шагом упорядочивания выборки: $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$. Для компактности представления генеральной совокупности в таблице 1 приведены крайние порядковые статистики (выборочный минимум и максимум), а также вариационный размах $R = x_{(n)} - x_{(1)}$ для каждой переменной.

Таблица 1: Экстремальные значения вариационных рядов

Порядковая статистика	X_1	X_2	X_3
Минимум, $x_{(1)}$	36.9700	44.5600	23.5200
Максимум, $x_{(n)}$	91.9500	124.3300	178.7100
Вариационный размах, R	54.9800	79.7700	155.1900

2.4 Эмпирические результаты вычислений

На основе представленных выше математических формул с использованием программных средств были произведены вычисления для основных исследуемых переменных X_1 , X_2 и X_3 . Результаты сведены в таблицу 2.

Таблица 2: Сводные точечные оценки числовых характеристик выборок

Статистическая характеристика	X_1	X_2	X_3
Выборочное среднее ($\bar{x}$)	65.4727	79.3980	60.2146
Выборочная дисперсия (S^2)	242.7446	189.8900	1093.9135
Исправленная дисперсия ($\hat{\sigma}^2$)	243.9644	190.8442	1099.4105
Стандартное отклонение (S)	15.5803	13.7801	33.0744
Выборочная медиана (m_e)	66.1300	80.1750	50.8900
Первый (нижний) квартиль (Q_1)	52.6750	70.1150	34.8100
Третий (верхний) квартиль (Q_3)	79.0200	89.5475	75.3200

Сравнение выборочного среднего и медианы уже на данном этапе позволяет сделать предварительные выводы о симметричности распределений. Для величин X_1 ($65.47 \approx 66.13$) и X_2 ($79.39 \approx 80.17$) наблюдается ярко выраженная симметрия. В то же время для X_3 значительное превышение среднего над медианой ($60.21 > 50.89$) свидетельствует о сильной правосторонней асимметрии (скошенности) распределения.

3 Интервальная группировка и визуализация данных

3.1 Теоретическое обоснование методов визуализации

Для непрерывных случайных величин точечные графики малоинформативны ввиду того, что вероятность повторения конкретного вещественного значения стремится к нулю. Поэтому основным инструментом визуального разведочного анализа является переход от вариационного ряда к интервальному статистическому ряду и построение гистограммы плотности частот.

1. Эмпирическая функция распределения (ЭФР). Эмпирическая функция распределения $F_n(x)$ — это ступенчатая функция, скачки которой происходят в точках, соответствующих наблюдаемым значениям выборки. Величина скачка пропорциональна кратности наблюдения. Формально ЭФР задается как:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x) \quad (7)$$

где $I(A)$ — индикаторная функция события A . Согласно фундаментальной теореме Гливенко-Кантелли, при $n \rightarrow \infty$ эмпирическая функция $F_n(x)$ равномерно сходится к истинной (теоретической) функции распределения $F(x)$ с вероятностью единица.

2. Правило Стерджеса и построение гистограммы. На этапе предварительного анализа тестировались различные алгоритмы интервальной группировки: правило Стерджеса, правило Скотта (опирающееся на стандартное отклонение) и правило Фридмана-Диакониса (опирающееся на межквартильный размах). Результаты расчета оптимального количества интервалов k представлены в таблице 3.

Таблица 3: Сравнение алгоритмов вычисления количества интервалов ($n = 200$)

Правило	X_1	X_2	X_3
Стерджеса ($k \approx 1 + \log_2 n$)	8	8	8
Скотта ($h = 3.49\hat{\sigma}n^{-1/3}$)	6	10	8
Фридмана-Диакониса ($h = 2IQRn^{-1/3}$)	7	12	12

Как видно из таблицы, альтернативные правила предлагают от 6 до 12 интервалов в зависимости от дисперсии конкретной переменной. Однако классическое правило Стерджеса ($k = 8$) оказалось наиболее сбалансированным для всех трех столбцов: оно предотвратило излишнюю фрагментацию гистограмм (как в случае $k = 12$ для X_3) и позволило визуально четче выявить макроструктуру распределений.

$$k = 1 + \lfloor \log_2 n \rfloor \quad (8)$$

Для рассматриваемой выборки объемом $n = 200$ получаем:

$$k = 1 + \lfloor \log_2 200 \rfloor = 1 + 7 = 8 \text{ интервалов.} \quad (9)$$

Шаг интервала h вычисляется как $h = \frac{x_{(n)} - x_{(1)}}{k}$. По оси ординат гистограммы откладывается плотность относительной частоты $f_i = \frac{n_i}{n \cdot h}$, где n_i — количество элементов выборки, попавших в i -й интервал. Площадь всех прямоугольников гистограммы строго равна 1.

3.2 Визуальный анализ переменной X_1

На рисунке ниже представлены графики эмпирической функции распределения и гистограммы плотности частот для случайной величины X_1 .




Рис. 1: ЭФР и гистограмма для выборки X_1

Анализ формы распределения X_1 : Гистограмма демонстрирует практически прямоугольную (уплощённую) форму, лишённую ярко выраженного центрального пика. Частоты распределены по интервалам относительно равномерно. Явных выбросов (аномальных наблюдений) не зафиксировано, распределение визуально симметрично и строго ограничено границами выборки как слева, так и справа. Тот факт, что выборочное среднее (65.47) и медиана (66.13) практически совпадают, математически подтверждает общую структурную симметрию данных.

3.3 Визуальный анализ переменной X_2

На рисунке ниже представлены графики эмпирической функции распределения и гистограммы плотности частот для случайной величины X_2 .




Рис. 2: ЭФР и гистограмма для выборки X_2

Анализ формы распределения X_2 : График плотности имеет классическую выраженную колоколообразную форму. Наблюдается централизация данных вокруг единого максимума. Асимметрия полностью отсутствует, правый и левый хвосты спадают к границам равномерно и плавно. Равенство медианы (80.17) и математического ожидания (79.39) свидетельствует в пользу гипотезы об отсутствии какой-либо скошенности. Эмпирическая функция распределения имеет характерную S-образную (сигмоидную) форму.

3.4 Визуальный анализ переменной X_3

На рисунке ниже представлены графики эмпирической функции распределения и гистограммы плотности частот для случайной величины X_3 .




Рис. 3: ЭФР и гистограмма для выборки X_3

Анализ формы распределения X_3 : Гистограмма демонстрирует сильную правостороннюю асимметрию (положительную скошенность). Подавляющая масса данных сконцентрирована в левой части графика, образуя крутой пик вблизи минимального значения. При этом наблюдается длинный, медленно убывающий правый «хвост». Распределение физически ограничено нулём с левой стороны. Сильное расхождение между средним значением (60.21) и медианой (50.89) обусловлено тем, что крупные значения в правом хвосте «оттягивают» на себя среднее арифметическое, в то время как робастная медиана остается в зоне наибольшей концентрации данных.

4 Идентификация теоретических законов распределения

Переход от непараметрического описания (гистограмм) к параметрическим моделям позволяет сжать информацию о выборке до нескольких числовых параметров. Выдвижение статистических гипотез о виде распределения осуществляется на базе визуального сопоставления формы гистограммы с графиками известных плотностей вероятности, а также на основе анализа точечных оценок (в частности, соотношения среднего и медианы).

4.1 Теоретические справки по рассматриваемым моделям

1. Непрерывное равномерное распределение $U(a, b)$. Характеризуется тем, что случайная величина принимает значения на интервале $[a, b]$ с постоянной плотностью вероятности:

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & x \notin [a, b] \end{cases} \quad (10)$$

2. Нормальное распределение Гаусса $N(a, \sigma^2)$. Важнейшее распределение в статистике, возникающее в результате суммирования множества независимых слабо влияющих факторов (Центральная предельная теорема). Плотность вероятности имеет вид:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-a)^2}{2\sigma^2}\right), \quad x \in (-\infty, +\infty) \quad (11)$$

3. Экспоненциальное распределение со сдвигом $Exp(\lambda, c)$. Описывает время между наступлениями редких событий или наработку на отказ. Сдвиг c задает минимально возможное значение случайной величины:

$$f(x) = \begin{cases} \lambda e^{-\lambda(x-c)}, & x \geq c \\ 0, & x < c \end{cases} \quad (12)$$

4.2 Обоснование выбора распределений для X_1, X_2, X_3

Опираясь на проведенный разведочный анализ, мы постулируем следующие структурные модели для исследуемых выборок:

1. Столбец X_1 — Равномерное распределение $U_{a,b}$.

Обоснование: Форма гистограммы визуально близка к прямоугольной (плотность вероятности практически константа на рабочем отрезке). Дополнительно можно провести грубую аналитическую проверку: теоретическая дисперсия равномерного закона равна $DX = (b-a)^2/12$. Если подставить эмпирический минимум (36.97)

и максимум (91.95), мы получим ≈ 251.9 , что ...крайне близко к истинным оценкам дисперсии (выборочной смещённой $S^2 = 242.74$ и исправленной $\hat{\sigma}^2 = 243.96$).

2. Столбец X_2 — Нормальное распределение $N_{a,\sigma}$.

Обоснование: Колоколообразная форма графика плотности, симметричность левого и правого хвостов, а также практически идеальное совпадение выборочного математического ожидания и медианы являются характерными визуальными признаками нормального распределения.

3. Столбец X_3 — Экспоненциальное распределение со сдвигом $Exp_{\lambda,c}$.

Обоснование: Наблюдается явная асимметрия, выборка ограничена слева и имеет монотонно убывающий правый хвост. Наличие сдвига c очевидно, так как минимальное значение в выборке (23.52) существенно оторвано от нуля. Выполнение неравенства $\bar{x} > m_e$ является дополнительным весомым аргументом в пользу гипотезы об экспоненциальной природе данных.

5 Оценивание параметров теоретических моделей

После того как на основе визуального и первичного количественного анализа были выдвинуты гипотезы о виде законов распределения для каждой из рассматриваемых случайных величин, необходимо найти точечные оценки неизвестных параметров этих распределений.

Для решения данной задачи в математической статистике традиционно применяются два фундаментальных подхода: метод моментов (ММ) и метод максимального правдоподобия (ММП).

5.1 Теоретико-методологическая база

1. Метод моментов (ММ). Суть метода, предложенного Карлом Пирсоном, заключается в приравнивании теоретических моментов рассматриваемого распределения (которые зависят от неизвестных параметров) к соответствующим эмпирическим (выборочным) моментам, вычисленным по данным наблюдений. Для распределений с двумя неизвестными параметрами (как в нашем случае) необходимо составить систему из двух уравнений, приравнивая математическое ожидание EX к выборочному среднему $\bar{x}$, а теоретическую дисперсию DX — к выборочной смещенной дисперсии S^2 :

$$\begin{cases} EX(\theta_1, \theta_2) = \bar{x} \\ DX(\theta_1, \theta_2) = S^2 \end{cases} \quad (13)$$

Решение этой системы дает оценки метода моментов $\hat{\theta}_1, \hat{\theta}_2$.

2. Метод максимального правдоподобия (ММП). Метод Фишера базируется на построении функции правдоподобия $L(\theta)$, которая представляет собой совместную плотность вероятности получения именно той выборки, которая наблюдается в эксперименте:

$$L(\theta_1, \theta_2) = \prod_{i=1}^n f(x_i | \theta_1, \theta_2) \quad (14)$$

В качестве оценок $\hat{\theta}_1, \hat{\theta}_2$ принимаются такие значения параметров, которые максимизируют функцию L . Поскольку точка максимума функции совпадает с точкой максимума её логарифма (ввиду монотонности логарифмической функции), на практике максимизируют логарифмическую функцию правдоподобия $l(\theta) = \ln L(\theta)$, решая систему уравнений:

$$\begin{cases} \frac{\partial l}{\partial \theta_1} = 0 \\ \frac{\partial l}{\partial \theta_2} = 0 \end{cases} \quad (15)$$

5.2 Оценки для равномерного распределения (Столбец X_1)

Предполагаемая модель: $X_1 \sim U(a, b)$. Неизвестные параметры — границы интервала a и b .

Метод моментов (ММ): Теоретические моменты равномерного распределения равны: $EX = \frac{a+b}{2}$ и $DX = \frac{(b-a)^2}{12}$. Составляем систему:

$$\begin{cases} \frac{a+b}{2} = \bar{x} \\ \frac{(b-a)^2}{12} = S^2 \end{cases} \quad (16)$$

Из первого уравнения выражаем сумму $a + b = 2\bar{x}$. Из второго уравнения находим разность $b - a = \sqrt{12S^2} = 2\sqrt{3}S$. Складывая и вычитая полученные выражения, находим оценки:

$$\begin{cases} \hat{a}_{mm} = \bar{x} - \sqrt{3}S \\ \hat{b}_{mm} = \bar{x} + \sqrt{3}S \end{cases} \quad (17)$$

Подставляя эмпирические значения $\bar{x} = 65.4727$ и $S^2 = 242.7446$, получаем:

$$\hat{a}_{mm} = 38.4869, \quad \hat{b}_{mm} = 92.4586 \quad (18)$$

Метод максимального правдоподобия (ММП): Функция правдоподобия имеет вид:

$$L(a, b) = \prod_{i=1}^n \frac{1}{b-a} = \frac{1}{(b-a)^n} \quad (19)$$

Данная функция возрастает при уменьшении разности $(b-a)$. Следовательно, для максимизации L необходимо выбрать минимально возможную длину интервала $[a, b]$, но так, чтобы он накрывал все элементы выборки. Отсюда следует, что:

$$\hat{a}_{mle} = \min_{1 \leq i \leq n} x_i, \quad \hat{b}_{mle} = \max_{1 \leq i \leq n} x_i \quad (20)$$

Обращаясь к вариационному ряду, получаем:

$$\hat{a}_{mle} = 36.9700, \quad \hat{b}_{mle} = 91.9500 \quad (21)$$

Сравнительный анализ: Оценки обоими методами оказались близки друг к другу. Оценки ММП жёстко привязаны к экстремальным значениям выборки, в то время как оценки ММ слегка "сглаживают" границы за счет опоры на дисперсию.

5.3 Оценки для нормального распределения (Столбец X_2)

Предполагаемая модель: $X_2 \sim N(a, \sigma^2)$. Неизвестные параметры: математическое ожидание a и дисперсия σ^2 .

Метод моментов (ММ): Теоретические моменты распределения Гаусса: $EX = a$ и $DX = \sigma^2$. Система уравнений метода моментов тривиальна:

$$\begin{cases} a = \bar{x} \\ \sigma^2 = S^2 \end{cases} \quad (22)$$

Подставляем эмпирические данные:

$$\hat{a}_{mm} = 79.3980, \quad \hat{\sigma}_{mm}^2 = 189.8900 \quad (23)$$

Метод максимального правдоподобия (ММП): Логарифмическая функция правдоподобия:

$$l(a, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - a)^2 \quad (24)$$

Находим частные производные по параметрам и приравниваем их к нулю:

$$\frac{\partial l}{\partial a} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - a) = 0 \implies \sum_{i=1}^n x_i - na = 0 \implies \hat{a}_{mle} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \quad (25)$$

$$\frac{\partial l}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \hat{a})^2 = 0 \implies \hat{\sigma}_{mle}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = S^2 \quad (26)$$

Числовые значения полностью совпадают с оценками метода моментов:

$$\hat{a}_{mle} = 79.3980, \quad \hat{\sigma}_{mle}^2 = 189.8900 \quad (27)$$

5.4 Оценки для экспоненциального распределения со сдвигом (Столбец X_3)

Предполагаемая модель: $X_3 \sim \text{Exp}(\lambda, c)$. Неизвестные параметры: интенсивность λ и параметр сдвига c .

Метод моментов (ММ): Теоретические моменты: $EX = c + \frac{1}{\lambda}$ и $DX = \frac{1}{\lambda^2}$. Система уравнений:

$$\begin{cases} c + \frac{1}{\lambda} = \bar{x} \\ \frac{1}{\lambda^2} = S^2 \end{cases} \quad (28)$$

Из второго уравнения находим $\hat{\lambda} = \frac{1}{S}$. Подставляем в первое и выражаем сдвиг: $\hat{c} = \bar{x} - S$. Числовые значения ($\bar{x} = 60.2146$, $S = 33.0744$):

$$\hat{\lambda}_{mm} = 0.0642, \quad \hat{c}_{mm} = 49.8925 \quad (29)$$

Критическое замечание: Полученная оценка сдвига $\hat{c}_{mm} = 49.8925$ противоречит здравому смыслу и физической природе данных, так как в исходной выборке присутствуют значения (начиная от минимума 23.52), которые строго меньше рассчитанного сдвига. Модель с такими параметрами припишет нулевую вероятность реально наблюдаемым событиям. Это демонстрирует уязвимость метода моментов для асимметричных распределений со сдвигом.

Метод максимального правдоподобия (ММП): Функция правдоподобия с учетом индикаторной функции $x_i \geq c$:

$$L(\lambda, c) = \prod_{i=1}^n \lambda e^{-\lambda(x_i - c)} = \lambda^n e^{-\lambda \sum (x_i - c)}, \quad \text{при } \min(x_i) \geq c \quad (30)$$

Для максимизации экспоненты необходимо сделать сумму $\sum (x_i - c)$ минимальной, что эквивалентно максимизации параметра c . Однако c не может превышать минимальный элемент выборки. Таким образом, оценка сдвига фиксируется по экстремальной статистике:

$$\hat{c}_{mle} = \min_{1 \leq i \leq n} x_i = 23.5200 \quad (31)$$

Подставляя $\hat{c}$ в логарифмическую функцию правдоподобия и дифференцируя по λ :

$$\frac{\partial}{\partial \lambda} \left(n \ln \lambda - \lambda \sum_{i=1}^n (x_i - \hat{c}) \right) = \frac{n}{\lambda} - \sum_{i=1}^n (x_i - \hat{c}) = 0 \quad (32)$$

$$\hat{\lambda}_{mle} = \frac{n}{\sum (x_i - \hat{c})} = \frac{1}{\bar{x} - \hat{c}} \quad (33)$$

Подставляя числовые значения, получаем корректные оценки:

$$\hat{c}_{mle} = 23.5200, \quad \hat{\lambda}_{mle} = 0.0273 \quad (34)$$

В дальнейших аналитических расчетах для переменной X_3 будут использоваться исключительно состоятельные оценки метода максимального правдоподобия.

6 Оценка параметрической вероятности редких событий

Важным этапом статистического моделирования является верификация выбранных теоретических моделей. Одним из эффективных способов проверки адекватности модели (помимо формальных критериев согласия) является сравнение эмпирической и теоретической (параметрической) вероятностей попадания случайной величины в заданную критическую область. В статистической практике особый интерес представляет анализ «правого хвоста» распределения, то есть вероятности превышения некоторого заданного порога x_0 .

6.1 Методология оценивания

В качестве порогового значения для всех трех случайных величин выбрана величина, отстоящая от выборочного математического ожидания вправо на одно стандартное отклонение:

$$x_0 = \bar{x} + \hat{\sigma} \quad (35)$$

Оценивание вероятности $P(X > x_0)$ производится двумя независимыми способами:

1. **Эмпирический непараметрический метод.** Оценка вероятности вычисляется как относительная частота наступления события в исходной выборке:

$$\hat{P}_{emp}(X > x_0) = \frac{1}{n} \sum_{i=1}^n I(x_i > x_0) \quad (36)$$

где $I(\cdot)$ — индикаторная функция, принимающая значение 1, если условие выполнено, и 0 в противном случае.

2. **Теоретический параметрический метод.** Вероятность вычисляется аналитически через интеграл от функции плотности $f(x, \hat{\theta})$ с подставленными точечными оценками параметров, полученными методом максимального правдоподобия:

$$P_{param}(X > x_0) = \int_{x_0}^{+\infty} f(x, \hat{\theta}_{mle}) dx = 1 - F(x_0, \hat{\theta}_{mle}) \quad (37)$$

где $F(x)$ — интегральная функция распределения.

6.2 Аналитические расчеты для исследуемых величин

1. Анализ переменной $X_1 \sim U(36.97, 91.95)$: Вычисляем пороговое значение: $x_0 = 65.4727 + 15.6194 = 81.0921$. Эмпирическая частота: в выборке зафиксировано 44 значения, превышающих данный порог. Следовательно, $\hat{P}_{emp} = 44/200 = 0.2200$. Параметрическая вероятность для равномерного закона вычисляется через линейную функцию распределения:

$$P_{param}(X_1 > 81.0921) = 1 - \frac{x_0 - \hat{a}}{\hat{b} - \hat{a}} = 1 - \frac{81.0921 - 36.9700}{91.9500 - 36.9700} = 0.1978 \quad (38)$$

2. Анализ переменной $X_2 \sim N(79.3980, 189.8900)$: Пороговое значение: $x_0 = 79.3980 + \sqrt{189.8900} = 93.2127$. Эмпирическая частота: 33 значения в выборке превышают порог. $\hat{P}_{emp} = 33/200 = 0.1650$. Параметрическая вероятность вычисляется через стандартизацию и функцию Лапласа $\Phi(z)$:

$$Z = \frac{x_0 - \hat{a}}{\hat{\sigma}} = \frac{93.2127 - 79.3980}{13.7801} \approx 1.0025 \quad (39)$$

$$P_{param}(X_2 > 93.2127) = 1 - \Phi(1.0025) \approx 0.1581 \quad (40)$$

3. Анализ переменной $X_3 \sim Exp(0.0273, 23.5200)$: Пороговое значение: $x_0 = 60.2146 + 33.1573 = 93.3720$. Эмпирическая частота: 31 значение превышает порог. $\hat{P}_{emp} = 31/200 = 0.1550$. Параметрическая вероятность вычисляется через интегрирование экспоненциальной плотности:

$$P_{param}(X_3 > 93.3720) = \int_{x_0}^{+\infty} \lambda e^{-\lambda(x-c)} dx = e^{-\lambda(x_0-c)} \quad (41)$$

$$P_{param}(X_3 > 93.3720) = \exp(-0.0273 \cdot (93.3720 - 23.5200)) = 0.1485 \quad (42)$$

6.3 Сравнительный анализ вероятностей

Для наглядности полученные результаты сведены в таблицу 4.

Таблица 4: Сравнение эмпирических и параметрических оценок вероятностей

Переменная	Порог x_0	Эмпирическая $\hat{P}$	Параметрическая P	Абс. разность Δ
X_1 (Равномерное)	81.0921	0.2200	0.1978	0.0222
X_2 (Нормальное)	93.2127	0.1650	0.1581	0.0069
X_3 (Экспоненциальное)	93.3720	0.1550	0.1485	0.0065

Вывод: Как видно из таблицы, абсолютная разность между эмпирическими частотами и теоретическими вероятностями составляет менее 1-2%. Столь высокая степень согласованности в зоне "хвостов" (где данных экспоненциально меньше) является строгим и убедительным доказательством того, что выбранные математические модели и

найденные точечные оценки параметров обладают высокой репрезентативностью и прогностической силой.

7 Оценка моментов по сгруппированной выборке

В реальных исследовательских и промышленных задачах исследователю не всегда доступны «сырые» исходные данные (raw data). Из соображений экономии памяти, обеспечения конфиденциальности или из-за особенностей измерительной аппаратуры данные часто предоставляются в сгруппированном (интервальном) виде — в формате гистограмм частот.

7.1 Математическая постановка задачи группировки

Пусть диапазон значений выборки разбит на m непересекающихся интервалов. Известны лишь середины этих интервалов $\hat{X}_k$ и абсолютные частоты (количество наблюдений) n_k , попавших в каждый k -й интервал. Истинные значения x_i внутри интервалов считаются неизвестными. При этом предполагается, что элементы внутри каждого интервала сконцентрированы в его середине. Оценки математического ожидания и дисперсии по сгруппированным данным вычисляются по формулам взвешенного среднего:

$$\hat{X}_g = \frac{1}{n} \sum_{k=1}^m n_k \hat{X}_k \quad (43)$$

$$\hat{\sigma}_g^2 = \frac{1}{n-1} \sum_{k=1}^m n_k (\hat{X}_k - \hat{X}_g)^2 \quad (44)$$

Очевидно, что переход от непрерывных данных к дискретным интервалам влечет за собой потерю информации (ошибку квантования). Наша задача — количественно оценить степень этой потери.

7.2 Результаты пересчета моментов

Используя $k = 8$ интервалов, полученных ранее по правилу Стерджеса, произведен пересчет характеристик. В таблице 5 представлено сравнение истинных моментов (по сырым данным) и приближенных (по сгруппированным).

Таблица 5: Сравнение моментов исходной и сгруппированной выборок

Переменная	Математическое ожидание		Исправленная дисперсия	
	Исходное ($\bar{x}$)	Сгруппир. ($\hat{X}_g$)	Исходная ($\hat{\sigma}^2$)	Сгруппир. ($\hat{\sigma}_g^2$)
X_1	65.4727	65.4565	243.9644	234.4462
X_2	79.3980	79.2599	190.8442	196.8132
X_3	60.2146	61.6385	1099.4105	1069.8498

Анализ ошибки группировки: Анализ таблицы показывает, что оценка математического ожидания обладает высокой устойчивостью к группировке. Отклонения $\hat{X}_g$

от $\bar{x}$ во всех трех случаях пренебрежимо малы и не превышают 2%. В то же время оценка дисперсии подвержена более сильному искажению. Это фундаментальное следствие искусственной дискретизации: при группировке мы постулируем, что дисперсия данных внутри каждого отдельно взятого интервала равна нулю (все точки "слипаются" в середине интервала), что неизбежно искажает общую картину рассеяния. Тем не менее, для задач экспресс-анализа сгруппированные оценки сохраняют достаточную репрезентативность.

8 Интервальное оценивание параметров

Точечные оценки (математическое ожидание, дисперсия), полученные в предыдущих разделах, являются приближенными значениями неизвестных параметров генеральной совокупности. Однако точечная оценка не содержит информации о своей точности и надежности. Для решения этой проблемы строится доверительный интервал — интервал, который с заданной вероятностью (уровнем доверия) $\gamma = 1 - \alpha$ покрывает истинное значение параметра.

В рамках данной работы уровень доверия зафиксирован на стандартной отметке $\gamma = 0.95$ (уровень значимости $\alpha = 0.05$).

8.1 Асимптотические доверительные интервалы для EX

Согласно Центральной предельной теореме (ЦПТ), при достаточно большом объеме выборки ($n = 200 \gg 30$) выборочное среднее распределено асимптотически нормально. Для расчетов строго используется несмещенная оценка стандартного отклонения $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$. Формула для построения двустороннего асимптотического интервала:

$$EX \in \left(\bar{x} - z_{1-\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}}, \quad \bar{x} + z_{1-\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}} \right) \quad (45)$$

где $z_{0.975} = 1.96$. Произведем расчеты:

- Для X_1 : $\bar{x} = 65.4727$, $\hat{\sigma} = \sqrt{243.9644} = 15.6194$.
Радиус: $\delta = 1.96 \cdot \frac{15.6194}{\sqrt{200}} \approx 2.1647$. Интервал: **(63.3080; 67.6374)**
- Для X_2 : $\bar{x} = 79.3980$, $\hat{\sigma} = \sqrt{190.8442} = 13.8146$.
Радиус: $\delta = 1.96 \cdot \frac{13.8146}{\sqrt{200}} \approx 1.9145$. Интервал: **(77.4835; 81.3125)**
- Для X_3 : $\bar{x} = 60.2146$, $\hat{\sigma} = \sqrt{1099.4105} = 33.1574$.
Радиус: $\delta = 1.96 \cdot \frac{33.1574}{\sqrt{200}} \approx 4.5954$. Интервал: **(55.6192; 64.8100)**

8.2 Точные доверительные интервалы для нормального закона (X_2)

Для переменной $X_2 \sim N(a, \sigma^2)$ мы имеем возможность построить точные интервалы.

1. Интервал для математического ожидания a при неизвестной дисперсии.

Используется статистика Стьюдента с $k = n - 1$ степенями свободы.

$$a \in \left(\bar{x} - t_{1-\alpha/2, n-1} \frac{\hat{\sigma}}{\sqrt{n}}, \quad \bar{x} + t_{1-\alpha/2, n-1} \frac{\hat{\sigma}}{\sqrt{n}} \right) \quad (46)$$

Квантиль $t_{0.975, 199} \approx 1.9720$. Вычисляем радиус $\delta = 1.9720 \cdot \frac{13.8146}{\sqrt{200}} \approx 1.9262$. Получаем точный интервал:

$$a \in (77.4718; 81.3242) \quad (47)$$

Примечание: Точный интервал Стьюдента оказался чуть шире асимптотического нормального интервала, что логично отражает дополнительную неопределенность из-за неизвестной дисперсии генеральной совокупности.

2. Интервал для дисперсии σ^2 . Используется статистика $V = \frac{(n-1)\hat{\sigma}^2}{\sigma^2}$, которая подчиняется распределению Хи-квадрат (χ^2) с $n - 1$ степенями свободы. Двусторонний интервал имеет асимметричный вид (ввиду асимметрии самого распределения χ^2):

$$\sigma^2 \in \left(\frac{(n-1)\hat{\sigma}^2}{\chi_{1-\alpha/2, n-1}^2}, \quad \frac{(n-1)\hat{\sigma}^2}{\chi_{\alpha/2, n-1}^2} \right) \quad (48)$$

Квантили распределения χ^2 для 199 степеней свободы: $\chi_{0.975, 199}^2 \approx 239.95$ и $\chi_{0.025, 199}^2 \approx 161.82$. Выполняем расчеты:

$$\sigma^2 \in \left(\frac{199 \cdot 190.8442}{239.95}, \quad \frac{199 \cdot 190.8442}{161.82} \right) \Rightarrow \sigma^2 \in (158.2678; 234.6800) \quad (49)$$

8.3 Интерпретация доверительного интервала

Необходимо подчеркнуть строгий математический смысл полученных результатов. Доверительный интервал (77.47; 81.32) для математического ожидания X_2 **не означает**, что истинный параметр a попадает туда с вероятностью 0.95. Истинный параметр является неизвестной константой (числом), а не случайной величиной, поэтому вероятность его нахождения в любом фиксированном интервале равна либо 1, либо 0.

Уровень доверия 0.95 относится к *самому методу построения*. Это означает, что если мы извлечем 100 независимых выборок такого же объема из той же генеральной совокупности и построим для каждой из них интервал по указанной формуле, то в среднем 95 из 100 построенных интервалов накроют истинное значение параметра.

9 Итоговый вывод по основной части

В рамках выполнения основной части расчётно-графической работы был реализован комплексный статистический анализ эмпирических данных.

1. Проведен разведочный анализ: построены вариационные ряды, ЭФР и гистограммы. По форме распределений и соотношению числовых характеристик (среднего и медианы) были успешно идентифицированы вероятностные модели:
 - $X_1 \sim U(36.97, 91.95)$ — равномерное распределение;
 - $X_2 \sim N(79.39, \sqrt{189.89})$ — нормальное распределение;
 - $X_3 \sim Exp(0.027, 23.52)$ — экспоненциальное распределение со сдвигом.
2. Оценки параметров, вычисленные методом максимального правдоподобия (ММП), продемонстрировали высокую физическую адекватность по сравнению с методом моментов (особенно для величины X_3 , где метод моментов дал математически некорректный сдвиг).
3. Оценка параметрических вероятностей $P(X > x_0)$ подтвердила корректность моделей: расхождение между теоретическими и эмпирическими частотами редких событий составило менее 2%.
4. Благодаря достаточному объёму выборки ($n = 200$) построенные доверительные интервалы получились узкими, что говорит о высокой точности и надёжности проведенного точечного оценивания. Практическая ценность исследования заключается в том, что массив «сырых» данных успешно сжат до компактных математических моделей, пригодных для последующего прогнозирования.

10 Бонус: Анализ бимодальности и кластеризация (X_4)

В рамках бонусного задания проведено исследование дополнительной случайной величины X_4 , объем выборки которой также составляет $n = 200$. Анализ этой переменной выходит за рамки стандартного моделирования простыми законами распределения, поскольку визуальный разведочный анализ выявил сложную внутреннюю структуру данных.

10.1 Визуальный анализ и выявление неоднородности

На рисунке 4 представлена гистограмма плотности частот выборки X_4 . Количество интервалов ($k = 8$) выбрано по правилу Стерджеса, аналогично предыдущим расчетам.




Рис. 4: Гистограмма столбца X_4 (проявление бимодальности)

Визуальный анализ гистограммы позволяет сделать однозначный вывод о том, что распределение переменной X_4 является неоднородным. На графике отчетливо прослеживается бимодальная (двухвершинная) структура: присутствуют два ярко выраженных локальных максимума плотности распределения.

Первый пик находится в зоне значений 40–60, второй, более мощный пик — в зоне 100–120. Между ними наблюдается глубокий провал частот (зона значений 70–90), где плотность вероятности стремится к нулю. Это классический признак того, что данная выборка является не однородной генеральной совокупностью, а смесью двух независимых вероятностных режимов (субпопуляций).

10.2 Обоснование необходимости кластеризации

В условиях бимодальности вычисление классических точечных оценок (например, выборочного среднего $\bar{x}$) для всей выборки целиком является статистически некорректной операцией. Проблема заключается в том, что "общее среднее" попадает именно в зону локального минимума частот. Модель, построенная на таком "среднем" будет описывать гипотетическое состояние системы, в котором она практически никогда не находится.

Поэтому для корректного моделирования бимодального процесса необходимо применить методы кластерного анализа, чтобы разделить смесь на однородные группы и анализировать каждую из них независимо.

10.3 Результаты разделения смеси (Кластеризация)

Используя пороговый фильтр (визуально установленный в зоне провала частот ≈ 80), выборка X_4 была разделена на два кластера. Для каждого полученного кластера были вычислены объемы n_k и выборочные средние $\bar{x}_{c,k}$.

Результаты кластеризации:

1. **Кластер 1:** $n_1 = 101$ наблюдение. Выборочное среднее $\bar{x}_{c,1} = 52.5750$.
2. **Кластер 2:** $n_2 = 99$ наблюдений. Выборочное среднее $\bar{x}_{c,2} = 110.6622$.

Вывод по бонусному заданию: Анализ кластеров подтверждает выдвинутую гипотезу о смеси распределений. Средние значения кластеров (52.5750 и 110.6622) идеально совпадают с центрами локальных максимумов на гистограмме. Это доказывает, что адекватное математическое моделирование переменной X_4 возможно только путем независимого описания каждого режима работы системы.

А Приложение А. Листинг программного обеспечения

Ниже представлен полный исходный код скрипта на языке Python, разработанный для автоматизации всех этапов статистического анализа, вычислений точечных оценок, построения графиков и доверительных интервалов.

А Приложение А. Программная реализация

В целях обеспечения воспроизводимости результатов, удобства проверки и интерактивного взаимодействия с исходным кодом, полная программная реализация статистического анализа вынесена в облачную вычислительную среду Google Colab.

Вычислительный скрипт написан на языке Python с применением библиотек `numpy`, `pandas`, `matplotlib` и `scipy.stats`. Он содержит алгоритмы выполнения всех этапов исследования: загрузку и предварительную обработку данных, расчет точечных оценок, построение ЭФР и гистограмм, нахождение оценок методами ММ и ММП, расчет доверительных интервалов и кластеризацию бимодальной выборки.

Ознакомиться с исходным кодом, а также запустить вычисления можно по следующей ссылке:

[Открыть Google Colab Notebook]