

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**

**ФГАОУ ВО «НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ ИТМО»**

ФПИИ

Образовательная программа: «Языковые модели и ИИ»

Отчёт по дисциплине «Математическая статистика»

Расчётно-графическая работа №3

«Регрессионные модели и их интерпретация»

Вариант: В-12

Авторы: Лебедев А. Е.,

Попов Г. И.

Группа: 30.2

Преподаватель: Савченко Татьяна Владимировна

Санкт-Петербург, 2026

Исходные данные (Вариант В-12)

В работе исследуется зависимость концентрации вещества в крови (отклик y) от времени (фактор x). Данные представляют собой срез из набора `datasets::Theoph` (испытуемый 8, фаза после первого часа). Число наблюдений $n = 7$. Прогноз необходимо выполнить для $x^* = 9,7262$.

Таблица 1: Экспериментальные данные

Номер наблюдения (i)	Время, ч (x)	Концентрация (y)
1	2.02	7.56
2	3.53	6.59
3	5.05	5.88
4	7.15	4.73
5	9.07	4.57
6	12.10	3.00
7	24.12	1.25

1 Диаграмма рассеяния и гипотеза о характере связи

Для визуального анализа зависимости построим диаграмму рассеяния (рис. 1).

Диаграмма рассеяния экспериментальных данных




Рис. 1: Зависимость концентрации от времени

Гипотеза о характере связи:

Как видно из графика, с увеличением времени концентрация монотонно убывает, однако скорость убывания не является постоянной. В первые часы падение происходит быстрее, а затем замедляется, и график асимптотически приближается к нулю (оси абсцисс).

Следовательно, связь между переменными является **обратной и нелинейной**. Учитывая физический смысл задачи (фармакокинетика, выведение препарата из крови во времени), можно предположить, что наилучшим образом данную зависимость опишет **показательная модель** вида $y = ae^{bx}$, характеризующая экспоненциальный спад.

2 Построение линейной и квадратичной моделей

2.1 Линейная модель

Уравнение парной линейной регрессии имеет вид:

$$\hat{y} = b_0 + b_1x \quad (1)$$

Для нахождения неизвестных параметров b_0 и b_1 воспользуемся методом наименьших квадратов (МНК). Система нормальных уравнений имеет вид:

$$\begin{cases} nb_0 + b_1 \sum x_i = \sum y_i \\ b_0 \sum x_i + b_1 \sum x_i^2 = \sum x_i y_i \end{cases} \quad (2)$$

Проведя вычисления на основе исходных данных ($n = 7$), получаем следующие значения коэффициентов: $b_1 \approx -0.2753$, $b_0 \approx 7.2762$.

Таким образом, уравнение линейной модели:

$$\hat{y} = 7.2762 - 0.2753x \quad (3)$$

2.2 Квадратичная модель

Уравнение квадратичной модели (параболы) имеет вид:

$$\hat{y} = c_0 + c_1x + c_2x^2 \quad (4)$$

Система нормальных уравнений МНК для квадратичной функции:

$$\begin{cases} nc_0 + c_1 \sum x_i + c_2 \sum x_i^2 = \sum y_i \\ c_0 \sum x_i + c_1 \sum x_i^2 + c_2 \sum x_i^3 = \sum x_i y_i \\ c_0 \sum x_i^2 + c_1 \sum x_i^3 + c_2 \sum x_i^4 = \sum x_i^2 y_i \end{cases} \quad (5)$$

Решая данную систему уравнений, получаем коэффициенты: $c_0 \approx 8.6434$, $c_1 \approx -0.6034$, $c_2 \approx 0.0123$.

Следовательно, уравнение квадратичной модели:

$$\hat{y} = 8.6434 - 0.6034x + 0.0123x^2 \quad (6)$$

3 Построение дополнительной модели

Опираясь на гипотезу из первого пункта, в качестве дополнительной была выбрана показательная модель:

$$\hat{y} = ae^{bx} \quad (7)$$

Для применения МНК нелинейную модель необходимо линеаризовать путём логарифмирования обеих частей уравнения:

$$\ln(\hat{y}) = \ln(a) + bx \quad (8)$$

Сделаем замену переменных: $Y = \ln(y)$ и $A = \ln(a)$. Тогда уравнение принимает линейный вид: $Y = A + bx$. Система нормальных уравнений для линеаризованной модели:

$$\begin{cases} nA + b \sum x_i = \sum Y_i \\ A \sum x_i + b \sum x_i^2 = \sum x_i Y_i \end{cases} \quad (9)$$

Рассчитав коэффициенты, получаем: $b \approx -0.0818$ и $A \approx 2.1761$. Возвращаясь к исходным переменным, находим $a = e^A = e^{2.1761} \approx 8.8119$.

Итоговое уравнение показательной модели:

$$\hat{y} = 8.8119 \cdot e^{-0.0818x} \quad (10)$$

4 Сравнение моделей

Для оценки качества построенных моделей рассчитаем основные метрики: коэффициент детерминации (R^2), корень из среднеквадратичной ошибки (RMSE) и среднюю ошибку аппроксимации (A).

Коэффициент детерминации показывает долю дисперсии зависимой переменной, объясняемую моделью. Средняя ошибка аппроксимации показывает среднее относительное отклонение расчетных значений от фактических (хорошим считается показатель $A < 10\%$).

Сводные результаты расчетов представлены в таблице 2.

Для наглядного сравнения построим графики всех трёх моделей на одной координатной плоскости вместе с исходными эмпирическими данными (рис. 2).

Вывод по сравнению моделей:

Как видно из таблицы и графика, линейная модель справляется с описанием данных

Таблица 2: Сравнение метрик качества моделей

Модель	R^2	RMSE	Ошибка аппрокс. A , %
Линейная	0.9127	0.5898	16.14
Квадратичная	0.9915	0.1837	3.03
Показательная	0.9907	0.1924	3.63




Рис. 2: Сравнение графиков регрессионных моделей

хуже остальных: средняя ошибка аппроксимации составляет более 16%, что делает её наименее точной.

Квадратичная и показательная модели показывают практически идентично высокие результаты ($R^2 > 0.99$, ошибка аппроксимации около 3-3.6%). С математической точки зрения парабола проходит чуть ближе к точкам, однако, исходя из смысловой (прикладной) интерпретации задачи, **показательная модель является наилучшей**. Квадратичная функция (с положительным коэффициентом при x^2) при $x > 25$ неизбежно начнёт возрастать, что абсурдно с биологической точки зрения (концентрация выводимого из крови вещества не может самопроизвольно увеличиваться). Экспоненциальная кривая корректно моделирует бесконечное приближение к нулю.

5 Анализ линейной модели

Выполним более глубокий статистический анализ для построенной линейной модели $\hat{y} = 7.2762 - 0.2753x$.

1. Расчёт остатков ($e_i = y_i - \hat{y}_i$):

Подставив эмпирические значения x_i в уравнение регрессии, найдём отклонения: $e_1 = 0.840$; $e_2 = 0.286$; $e_3 = -0.006$; $e_4 = -0.578$; $e_5 = -0.209$; $e_6 = -0.945$; $e_7 = 0.614$.

2. Остаточная сумма квадратов (RSS):

$$RSS = \sum_{i=1}^n e_i^2 \approx 2.4352 \quad (11)$$

3. Оценка дисперсии ошибки (S_e^2):

При числе степеней свободы $df = n - 2 = 7 - 2 = 5$, оценка дисперсии случайной ошибки составит:

$$S_e^2 = \frac{RSS}{n - 2} = \frac{2.4352}{5} \approx 0.4870 \quad (12)$$

4. Доверительные интервалы для коэффициентов:

Зададимся уровнем значимости $\alpha = 0.05$. Критическое значение t-критерия Стьюдента для $df = 5$ равно $t_{kp} = 2.571$. Рассчитаем стандартные ошибки коэффициентов: $S_{b_1} \approx 0.0381$ и $S_{b_0} \approx 0.4326$.

Доверительный интервал для параметра b_1 :

$$b_1 \pm t_{kp} \cdot S_{b_1} \implies -0.2753 \pm (2.571 \cdot 0.0381) \implies [-\mathbf{0.373}; -\mathbf{0.177}]$$

Доверительный интервал для параметра b_0 :

$$b_0 \pm t_{kp} \cdot S_{b_0} \implies 7.2762 \pm (2.571 \cdot 0.4326) \implies [\mathbf{6.164}; \mathbf{8.388}]$$

Так как доверительный интервал для b_1 не содержит нуль, фактор времени статистически значимо влияет на концентрацию вещества.

6 Выполнение прогноза

Согласно заданию, необходимо выполнить точечный прогноз концентрации по линейной модели при значении фактора $x^* = 9.7262$.

Подставим данное значение в уравнение линейной регрессии:

$$y^* = 7.2762 - 0.2753 \cdot (9.7262) \approx 7.2762 - 2.6776 = 4.5986 \quad (13)$$

Ответ: Прогнозное значение концентрации на момент времени $x = 9.7262$ часа составляет **4.60**.

ПРИЛОЖЕНИЕ. Программная реализация

Все вычислительные процедуры, оценка параметров по МНК, построение графиков и

расчёт метрик качества моделей были выполнены с использованием языка программирования Python (библиотеки NumPy, Pandas, SciPy, Matplotlib) в интерактивной среде Google Colab.

Ознакомиться с полным исходным кодом работы можно по ссылке:

<https://colab.research.google.com/drive/1Jcef37eH1WNPOnUkeqw6X1o8-3iJl0qM?usp=sharing>